

1 مقدمه

مقاله “Joint Channel Estimation and Feedback with Masked Token Transformers in Massive MIMO Systems” به بررسی یک روش نوین برای تخمین کانال (Channel Estimation) و فیدبک اطلاعات کانال (CSI Feedback) در سیستم‌های Massive MIMO می‌پردازد.

- سیستم‌های Massive MIMO دارای تعداد زیادی آنتن در ایستگاه پایه (BS) هستند و برای اینکه سیگنال به درستی منتقل شود، وضعیت کانال (CSI) باید دقیق تخمین زده شود.
- فیدبک CSI از کاربر (UE) به BS حجم بالایی دارد، بنابراین فشرده‌سازی و بازسازی داده‌ها ضروری است.
- مقاله یک مدل Masked Token Transformer (Encoder-Decoder) معرفی می‌کند که همزمان CSI را فشرده و بازسازی می‌کند.

2 سورس‌کد CSI Transformer

CSI Transformer یک پیاده‌سازی غیررسمی ولی مرتبط با مقاله است که در [GitHub](#) موجود است:

اجزای اصلی سورس‌کد:

- Encoder فشرده‌سازی (CSI):**
 - داده‌های CSI ورودی ماتریس‌های complex را دریافت می‌کند.
 - از **Multi-Head Attention** و **Layer Normalization** استفاده می‌کند.
 - خروجی یک نمایش فشرده و خلاصه از اطلاعات کانال است.
- Decoder بازسازی CSI:**
 - ورودی فشرده را می‌گیرد و CSI بازسازی شده را تولید می‌کند.
 - مشابه مقاله، هدف کمینه کردن خطای بازسازی (MSE Loss) است.
- Train.py و Test.py:**
 - train.py:** آموزش مدل روی داده‌های CSI مثلاً **COST2100 dataset**.
 - test.py:** تست مدل و بازسازی CSI، محاسبه معیارهای ارزیابی.
- Hyperparameters و Masking:**
 - برخی توکن‌ها در ورودی ماسک می‌شوند تا مدل **Self-Supervised Learning** یاد بگیرد.
 - این بخش مشابه **Masked Token Transformer** مقاله است.

3 اجرای مدل (مرحله به مرحله)

اگر بخواهیم مدل را اجرا کنیم:

- کلون کردن مخزن:
- نصب نیازمندی‌ها:
- آموزش مدل:

`python train.py`

- تست مدل و بازسازی CSI

`python test.py`

5. مشاهده خروجی:
- مدل CSI را بازسازی می‌کند.
 - می‌توان **Loss curve** و مقایسه CSI اصلی و بازسازی‌شده را رسم کرد.

4 ارتباط سورس‌کد با مقاله

1. **Encoder-Decoder Transformer:**
- مقاله از **Masked Token Transformer** استفاده می‌کند تا CSI را فشرده و بازسازی کند.
 - **CSI Transformer** همان ساختار کلی را پیاده‌سازی کرده است **Attention**، **Encoder-Decoder**، **Masked Tokens:**
 - مقاله برای یادگیری ویژگی‌های همبستگی فرکانسی و بازسازی بهتر از ماسک‌کردن توکن‌ها استفاده می‌کند.
 - **CSI Transformer** قابلیت مشابهی در بخش **Attention** و **Self-Supervised Learning** دارد.
 - 3. **تخمین کانال و فیدبک CSI:**
 - مقاله همزمان **Channel Estimation** و **CSI Feedback** را انجام می‌دهد.
 - **CSI Transformer** بیشتر روی فیدبک CSI تمرکز دارد، ولی مفاهیم مشابه فشرده‌سازی، بازسازی، **Loss** را نشان می‌دهد.

5 جمع بندی

- سورس‌کد **CSI Transformer** نمونه عملی پیاده‌سازی ترنسفورمر برای **CSI Feedback** در **Massive MIMO** است.
- با اجرای آن می‌توان ساختار شبکه، نحوه‌ی فشرده‌سازی و بازسازی **CSI**، ماسک کردن توکن‌ها و عملکرد مدل را مشاهده کرد.
- ارتباط مستقیم با مقاله:
 - مفاهیم **Masked Token** و **Transformer** برای فشرده‌سازی **CSI**
 - **Encoder-Decoder** برای بازسازی کانال
 - **Loss** و ارزیابی مشابه مقاله

در ضمن تمامی کدها در **src** میباشد

نکات تکمیلی و توصیه‌ها

- **درک معماری Transformer:** قبل از اجرای مدل، آشنایی با **Multi-Head Attention**، **LayerNorm**، **Encoder-Decoder** مفید است.
- **داده‌های CSI:** برای تمرین می‌توان از داده‌های شبیه‌سازی شده یا مجموعه داده‌های **COST2100** استفاده کرد.
- **Visualization:** رسم نمودار **CSI** بازسازی‌شده به صورت **Heatmap** یا سه‌بعدی، درک عملکرد مدل را بسیار راحت‌تر می‌کند.
- **گسترش مدل:** می‌توان بخش‌های **Masked Token** و **Decoder** را تغییر داد تا عملکرد شبیه مقاله واقعی شود.

توضیحات تکمیلی

در سیستم‌های ارتباطی مدرن، به‌ویژه در فناوری‌های بی‌سیم پیشرفته، پردازش داده‌های کانال به صورت بلادرنگ اهمیت بسیار بالایی دارد. الگوریتم‌ها و مدل‌های یادگیری عمیق می‌توانند کمک کنند تا سیستم‌ها بدون نیاز به ارسال حجم بالای داده از سمت کاربر، وضعیت کانال را به‌طور تقریبی ولی دقیق تخمین بزنند. یکی از راهکارهای جذاب، استفاده از شبکه‌های عصبی سبک و قابل گسترش است که ویژگی‌های پیچیده فرکانسی و زمانی را استخراج می‌کنند. این شبکه‌ها می‌توانند به‌صورت ماژولار طراحی شوند تا امکان ترکیب با سایر الگوریتم‌ها و مدل‌های بهینه‌سازی را داشته باشند.

در زمینه‌ی پیاده‌سازی، مدیریت داده‌ها و preprocessing نقش حیاتی دارد. داده‌های خام کانال معمولاً پیچیده هستند و باید به شکل ماتریسی یا توکن‌بندی مناسب تبدیل شوند تا شبکه بتواند روی آنها آموزش ببیند. به علاوه، متریک‌های ارزیابی متفاوتی مثل NMSE، MAE یا PSNR می‌توانند برای سنجش کیفیت بازسازی استفاده شوند، که هر کدام مزایا و محدودیت‌های خاص خود را دارند.

یکی دیگر از نکات مهم، افزایش قابلیت تعمیم مدل‌ها به کانال‌های ناشناخته است. مدل‌هایی که فقط روی یک نوع داده آموزش دیده‌اند، ممکن است در شرایط واقعی عملکرد قابل قبولی نداشته باشند. بنابراین استفاده از روش‌های regularization، dropout، data augmentation در آموزش شبکه اهمیت زیادی دارد.

علاوه بر این، در طراحی شبکه‌ها، محدودیت‌های زمانی و منابع محاسباتی باید مدنظر قرار گیرد. مدل‌های بسیار سنگین ممکن است در شبیه‌سازی دقیق یا پیاده‌سازی واقعی روی سخت‌افزارهای موبایل یا ایستگاه‌های پایه قابل استفاده نباشند. استفاده از معماری‌های سبک، parallelization و quantization می‌تواند کارایی مدل را افزایش دهد بدون آنکه دقت بازسازی کاهش یابد.

همچنین، در محیط‌های تحقیقاتی، مستندسازی و قابل اجرا بودن کد اهمیت دارد. یک پیاده‌سازی استاندارد و قابل فهم می‌تواند به سایر محققان کمک کند تا ایده‌ها را بررسی و توسعه دهند. در نهایت، ادغام مدل‌های یادگیری عمیق با الگوریتم‌های سنتی پردازش سیگنال می‌تواند کارایی کلی سیستم را به طور چشمگیری افزایش دهد، زیرا شبکه‌ها می‌توانند یادگیری خود را با اصول فیزیکی سیستم ترکیب کنند و خروجی‌هایی با دقت و پایداری بالاتر تولید کنند.

پایان

با تشکر از دکتر گران قدر